



Introducción a RAG (Retrieval Augmented Generation)

Septiembre 2026

Los modelos de
señados para g
des modelos s
por miles de


Models o LLMs) son sistemas de inteligencia artificial.

non miles d

-



Ciclo de entrenamiento



Objetivo: Enseñar al modelo a entender el lenguaje, gramática, conceptos y razonamiento general mediante la predicción del siguiente token.

Objetivo: Convertir el modelo base (que solo es un "completador de texto") en un asistente capaz de mantener conversaciones y seguir instrucciones.

Objetivo: Evaluar y reducir sesgos, alucinaciones o respuestas no deseadas

Next token prediction – The objective is to predict the token w_{t+1} given the previous tokens $w_1, \dots, w_t$.


a cute teddy bear is reading persian poetry

x y

In order to do so, we use the cross-entropy loss to minimize the deviation between the distribution of the predicted tokens and the target token.

Generación de texto por un LLM

La **generación autorregresiva** es la técnica fundamental con la que funcionan los modelos de lenguaje generativos.



- Iteración 1:

- Entrada:

```
<|im_start|>user\nHola Salamandra como estas?  
<|im_end|>\n<|im_start|>assistant\n
```

- Salida del modelo: Hola

- Iteración 2:

- Entrada:

```
<|im_start|>user\nHola Salamandra como estas?  
<|im_end|>\n<|im_start|>assistant\nHola
```

- Salida del modelo: ,

- Iteración 3:

- Entrada:

```
<|im_start|>user\nHola Salamandra como estas?  
<|im_end|>\n<|im_start|>assistant\nHola,
```

- Salida del modelo: estoy

- Iteración 4:

- Entrada:

```
<|im_start|>user\nHola Salamandra como estas?  
<|im_end|>\n<|im_start|>assistant\nHola, estoy
```

- Salida del modelo: bien

Conceptos importantes

1. Tokens

Son las unidades básicas de procesamiento (palabras, sílabas o caracteres). Los prompts y las respuestas se miden en tokens, lo cual afecta el costo y la longitud máxima procesable.

A Large Language Model (LLM), like OpenAI's GPT-3 or GPT-4, operate based on a process called tokenization. Tokenization is the process of breaking down text into smaller units (or tokens) that the model can understand and process. Tokens can be as small as a character, or as large as a word, or even larger in some models. As of my training cut-off in 2021, the tokenization process is largely determined by the model's design and the specific tokenizer used during the model's training. In the case of GPT-3 and GPT-4, they use a Byte Pair Encoding (BPE) tokenizer. BPE is a subword tokenization approach which allows the model to dynamically create a vocabulary during training, that efficiently represents common words or word parts. Free Julian Assange now. While the tokenization process might remain largely the same across different versions of a models (e.g., GPT-3 and GPT-4),

2. Ventana de Contexto (Context Window)

Es la cantidad máxima de tokens que el modelo "recuerda" en una interacción. Modelos recientes han expandido esto desde 4,000 tokens hasta 2 millones, permitiendo subir libros enteros como contexto.


¿Qué es RAG?

La generación aumentada por recuperación (RAG) es una técnica que permite a los grandes modelos de lenguaje (LLM) recuperar e incorporar nueva información.



¿Cuáles son las partes de RAG?

Un RAG típico funciona en dos etapas principales:



Fase 1: Indexación de Datos (El trabajo previo)


1. **Carga de documentación**
2. **Fragmentador (Chunker/Splitter)**
3. **Vectorización (Embedding)**
4. **Almacenamiento**



Fase 2: Recuperación y Generación (En tiempo real, al recibir una consulta)

5. **Recuperador (Retriever)**
6. **Incorporación al Prompt (Prompt Augmentation)**
7. **Generación de la Respuesta (LLM Generation)**

Diagrama



¿Qué ventajas ofrece?

- Respuestas actualizadas
- Reducción de "alucinaciones"
- Conocimiento especializado o privado
- Verificabilidad
- Eficiencia y ahorro de costos



Etapas de carga y preparación de la documentación:

En la etapa de **carga de la documentación**, el objetivo es transformar el material fuente (PDFs, informes, artículos, normas, etc.) en información **estructurada, limpia y semánticamente útil** para el recuperador.

Extracción y limpieza:

Se debe extraer el texto eliminando ruido (encabezados, pies de página, saltos de línea, numeraciones automáticas, etc.).



Tomar decisiones:

- Tablas
- Imágenes
- Fórmulas
- Diagramas
- Figuras




Fragmentador (Chunker/Splitter):

El **fragmentador** o **chunker** es encargado de dividir la documentación en **fragmentos más pequeños y coherentes**, llamados *chunks*.

El objetivo del fragmentador es **mantener el equilibrio entre tamaño, coherencia y contexto**


La división del texto puede basarse en diferentes formas:

- Fragmentación por longitud
- Fragmentación estructural




Vectorización (Embedding)

Cada fragmento de texto se convierte en un vector numérico usando un modelo de lenguaje especializado (un embedding model). Este vector es como una "huella digital" que captura el significado semántico del texto.




Los embeddings son el vínculo entre el lenguaje natural y el espacio matemático de búsqueda: el recuperador compara vectores en lugar de texto, lo que habilita una recuperación basada en significado y no en coincidencia literal.




Vectorización (Embedding)

Lo más utilizado para generar un vector de todo un pedazo de texto son los “Sentence Transformer”.

1. La Base: Un Modelo de Lenguaje Pre-entrenado (como BERT)
2. BERT no produce un único vector de "significado"
3. Pooling




Redes Siamesas



Indexación y Almacenamiento (Vector Store)


Estos vectores, junto con una referencia al fragmento de texto original, se cargan y se guardan en una base de datos vectorial. Esta base de datos está optimizada para buscar vectores semánticamente similares de forma muy eficiente.



Indexación y Almacenamiento (Vector Store)

Los algoritmos más comunes y famosos son:

- **Flat (brute force):** Compara el embedding de la consulta con todos los vectores almacenados.
- **HNSW (Hierarchical Navigable Small World):** Estructura tipo grafo jerárquico que conecta los vectores cercanos.
- **IVF (Inverted File System):** Agrupa vectores en centroides (clusters) y busca solo en los más cercanos.
- **PQ / OPQ (Product Quantization):** Comprime los vectores para ahorrar memoria y acelerar búsquedas.



Recuperador (Retriever)

La pregunta del usuario (el query) también se convierte en un vector usando el mismo modelo de embedding. El recuperador toma este vector y busca en la base de datos vectorial los fragmentos de texto cuyos vectores son más "cercaños" o similares semánticamente a la pregunta.




Incorporación al Prompt (Prompt Augmentation)

Los fragmentos de texto recuperados, que son el contexto más relevante para la pregunta, se insertan en una plantilla de prompt junto con la pregunta original del usuario.



Generación de la Respuesta (LLM Generation)

El prompt aumentado (pregunta + contexto recuperado) se envía finalmente al LLM. El modelo de lenguaje utiliza la información proporcionada para formular una respuesta completa, coherente y basada en los hechos recuperados.



Beneficios de ejecutar los modelos de forma local:

Privacidad y seguridad de los datos: Sus datos confidenciales nunca salen de su equipo. Ideal para información personal o empresarial confidencial.

Control y personalización: Tiene control total sobre el modelo, su configuración y cómo se integra en sus flujos de trabajo.

Reducción de costos (a largo plazo): Al usar modelos locales, elimina los costos de usar API en la nube, especialmente con un uso intensivo.

Operación sin conexión: Capacidad de operar sin conexión a internet (una vez descargado el modelo)

Desafíos de ejecutar los modelos de forma local:

Requisitos de hardware: Los LLM son exigentes. Necesita una CPU decente, suficiente RAM y, principalmente, una GPU.

Complejidad de configuración: Poner todo en funcionamiento requiere varios conocimientos técnicos.

Tamaño del modelo: Los modelos LLM pequeños para uso local pueden ocupar varios gigabytes de espacio.

Conocimiento limitado del modelo LLM pequeño: Los modelos base solo conocen la fecha de su último entrenamiento.

Bibliografía

https://en.wikipedia.org/wiki/Retrieval-augmented_generation

<https://www.marqo.ai/course/introduction-to-sentence-transformers>

<https://medium.com/@j13mehul/rag-part-4-indexing-1985f4000f72>

<https://www.oracle.com/ar/artificial-intelligence/generative-ai/retrieval-augmented-generation-rag/>

